

Contents

1	Introducción	2
2	Inssegadez	3
2.1	Definición	3
2.2	Interpretación	3
2.3	Propiedad: Linealidad de la Esperanza	3
2.4	Demostración de la inssegadez de la media muestral	4
2.5	Inssegadez de la varianza muestral y corrección de Bessel	4
2.6	Evidencia empírica mediante simulación	7
2.7	Representación gráfica	8
2.8	Relación con el Error Cuadrático Medio	8
2.9	Teorema de Rao-Blackwell	10
3	Eficiencia	11
3.1	Definición	11
3.2	Interpretación	12
3.3	Justificación mediante el Error Cuadrático Medio	12
3.4	Evidencia empírica mediante simulación	12
3.5	Comparación mediante densidades	13
3.6	Comparación mediante diagramas de caja	14
3.7	Comparación numérica de varianzas	16
3.8	Propiedad de mínima varianza	17
3.9	Relación entre Inssegadez y Eficiencia: Cota de Cramér-Rao	17
3.10	Interpretación	18
3.11	Eficiencia Relativa	18
4	Consistencia	19
4.1	Definición	19
4.2	Teoremas	19

4.3	Demostración para la Media Muestral	20
4.4	Verificación mediante R	21
5	Suficiencia	23
5.1	Definición	25
5.2	Implementación en R	26
5.3	Verificación mediante simulación en R	29
6	Conclusiones	31
7	Bibliografía	33

1 Introducción

En el contexto de la inferencia estadística, los estimadores puntuales son una herramienta fundamental la cual permite extrapolar información sobre una población a partir de una muestra. Su principal objetivo es proporcionar un único valor numérico que represente la mejor aproximación posible a un parámetro poblacional desconocido.

Es necesario hacer una diferencia entre estimador y estimación, un estimador es una función de una muestra, mientras que una estimación es el valor obtenido al aplicar un estimador a los datos de una muestra. Es decir, un estimador es una función de las variables aleatorias mientras que una estimación es una función de los valores muestrales.(López de Castilla Vásquez, 2012).

Sin embargo, no todos los estimadores ofrecen las mismas aproximaciones. Para poder evaluar y seleccionar el mejor estimador, se desarrollan las siguientes propiedades que permiten caracterizar su comportamiento:

- Insesgadez: Un estimador insesgado es aquel cuando, en promedio, su valor coincide con el parámetro poblacional al cual se pretende estimar. Es lo que garantiza que el estimador no tenga una tendencia a sobreestimar o subestimar.
- Eficiencia: De los estimadores insesgados, aquellos con menor varianza son considerados los más eficientes. Esta propiedad mide la precisión del estimador, es decir, que tan cercanas son sus estimaciones al rededor del valor real.
- Consistencia: Un estimador es llamado consistente cuando, al aumentar el tamaño de su muestra, la probabilidad de que su valor se aproxime al parámetro de la población tiende a uno. Esto asegura que el estimador mejora a medida que se aumenta la muestra o dispone de más información.
- Suficiencia: Es suficiente cuando el estimador condensa la información relevante que se tiene sobre el parámetro que contiene la muestra. Esta propiedad permite reducir la dimensionalidad de los datos sin perder información.

Es por ello que en el presente trabajo, se desarrollarán y explorarán las propiedades mencionadas mediante su definición teórica, verificación y simulación utilizando el lenguaje R, para así poder comprender mejor su importancia en la selección de estimadores óptimos.

2 Insesgadez

2.1 Definición

Sea $\hat{\theta}$ un estimador puntual de un parámetro θ . Se dice que $\hat{\theta}$ es un estimador insesgado si su valor esperado coincide con el parámetro que pretende estimar:

$$E(\hat{\theta}) = \theta$$

Equivalentemente, el sesgo se define como:

$$\text{Sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Por consiguiente, un estimador es insesgado cuando:

$$\text{Sesgo}(\hat{\theta}) = 0$$

2.2 Interpretación

La insesgadez indica que un estimador no tiende a sobreestimar ni subestimar el parámetro poblacional. En promedio, las estimaciones obtenidas a partir de muchas muestras coinciden con el valor real del parámetro.

2.3 Propiedad: Linealidad de la Esperanza

Una propiedad fundamental para demostrar la insesgadez es la linealidad de la esperanza. Si $X_1, X_2, \dots, X_n$ son variables aleatorias y $a_1, a_2, \dots, a_n$ son constantes, entonces:

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i)$$

Esta propiedad permite demostrar que numerosos estimadores utilizados en estadística son insesgados.

2.4 Demostración de la insesgadez de la media muestral

Sea:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

la media muestral de una muestra aleatoria simple.

Aplicando la linealidad de la esperanza:

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i) \end{aligned}$$

Como cada observación tiene media poblacional μ :

$$E(X_i) = \mu$$

entonces:

$$E(\bar{X}) = \frac{1}{n}(n\mu) = \mu$$

Por lo tanto:

$$E(\bar{X}) = \mu$$

lo que demuestra que la media muestral es un estimador insesgado de la media poblacional.

2.5 Insesgadez de la varianza muestral y corrección de Bessel

La estimación de la varianza poblacional presenta una dificultad adicional respecto a la estimación de la media. Consideremos el estimador:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

A primera vista, este estimador parece una elección natural para estimar la varianza poblacional (σ^2). Sin embargo, se demostrará que es un estimador sesgado.

2.5.1 Propiedad auxiliar

Se cumple la siguiente identidad:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

Tomando esperanza en ambos lados:

$$E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] - nE[(\bar{X} - \mu)^2]$$

2.5.2 Cálculo del primer término

Como:

$$Var(X_i) = \sigma^2$$

entonces:

$$E[(X_i - \mu)^2] = \sigma^2$$

y por linealidad de la esperanza:

$$E \left[\sum_{i=1}^n (X_i - \mu)^2 \right] = n\sigma^2$$

2.5.3 Cálculo del segundo término

Recordando que:

$$Var(\bar{X}) = \frac{\sigma^2}{n}$$

se tiene:

$$E[(\bar{X} - \mu)^2] = \frac{\sigma^2}{n}$$

Por consiguiente:

$$nE[(\bar{X} - \mu)^2] = \sigma^2$$

2.5.4 Resultado

Sustituyendo ambos resultados:

$$\begin{aligned} E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] &= n\sigma^2 - \sigma^2 \\ &= (n-1)\sigma^2 \end{aligned}$$

Por lo tanto:

$$\begin{aligned} E(S_n^2) &= E \left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \right] \\ &= \frac{1}{n} (n-1)\sigma^2 \end{aligned}$$

es decir,

$$E(S_n^2) = \frac{n-1}{n} \sigma^2$$

Como:

$$\frac{n-1}{n} \neq 1$$

se concluye que:

$$E(S_n^2) \neq \sigma^2$$

y, por tanto, (S_n^2) es un estimador sesgado de la varianza poblacional.

2.5.5 Corrección de Bessel

Para eliminar el sesgo se introduce el estimador:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Tomando esperanza:

$$E(S^2) = \frac{1}{n-1} E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right]$$

$$= \frac{1}{n-1}(n-1)\sigma^2$$

Por lo tanto:

$$E(S^2) = \sigma^2$$

Se concluye que (S^2) es un estimador insesgado de la varianza poblacional. El reemplazo de (n) por $(n-1)$ en el denominador se conoce como **corrección de Bessel** y compensa la pérdida de un grado de libertad ocasionada por la estimación previa de la media poblacional mediante $(\bar{X})$.

2.6 Evidencia empírica mediante simulación

Para complementar la demostración teórica, se realizó una simulación con $B = 10000$ (Número de repeticiones) y muestras aleatorias de tamaño $(n = 30)$, generadas a partir de una población con media poblacional $(\mu = 50)$ y desviación estándar $(\sigma = 10)$.

Para cada muestra se calculó la media muestral, obteniéndose una distribución de estimaciones del parámetro poblacional.

```
library(pacman)
```

```
## Warning: package 'pacman' was built under R version 4.5.3
```

```
p_load(ggplot2)
```

```
set.seed(123)
```

```
mu <- 50
```

```
sigma <- 10
```

```
n <- 30
```

```
B <- 10000
```

```
estimaciones <- replicate(
  B,
  mean(rnorm(n, mu, sigma))
)
```

El promedio de las estimaciones simuladas fue:

$$\bar{\hat{\mu}} = 50.01865$$

Dado que el verdadero valor del parámetro es:

$$\mu = 50$$

el sesgo empírico se estimó mediante:

$$\widehat{\text{Sesgo}} = \bar{\mu} - \mu$$

es decir,

$$\widehat{\text{Sesgo}} = 50.01865 - 50 = 0.01865$$

Este valor es muy próximo a cero, lo que indica que las estimaciones obtenidas se encuentran centradas alrededor del parámetro poblacional.

Debe tenerse en cuenta que el sesgo empírico no es exactamente nulo debido a la variabilidad inherente al proceso de simulación. Sin embargo, al aumentar el número de repeticiones, dicho valor tiende a aproximarse cada vez más a cero.

Por consiguiente, la simulación proporciona evidencia empírica consistente con el resultado teórico:

$$E(\bar{X}) = \mu$$

confirmando la propiedad de insesgadez de la media muestral.

2.7 Representación gráfica

La Figura muestra la distribución de las medias muestrales obtenidas mediante simulación. La línea discontinua representa el valor verdadero del parámetro poblacional (μ), mientras que la línea continua corresponde al promedio de las estimaciones simuladas.

La proximidad entre ambas líneas proporciona evidencia visual de que la media muestral constituye un estimador insesgado de la media poblacional.

Figura 1. Distribución de las estimaciones obtenidas mediante simulación. La coincidencia entre el parámetro verdadero y el promedio de las estimaciones constituye evidencia de la ausencia de sesgo.

2.8 Relación con el Error Cuadrático Medio

El error cuadrático medio (ECM) se define como:

$$ECM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$




Figure 1: Distribución muestral de la media.

y satisface la identidad:

$$ECM(\hat{\theta}) = Var(\hat{\theta}) + Sesgo^2(\hat{\theta})$$

Cuando el estimador es insesgado:

$$ECM(\hat{\theta}) = Var(\hat{\theta})$$

Esta relación muestra que, una vez eliminado el sesgo, la variabilidad del estimador se convierte en el principal criterio para evaluar su calidad.

2.9 Teorema de Rao-Blackwell

Una vez establecida la propiedad de insesgadez, surge el problema de determinar si un estimador insesgado puede mejorarse sin perder dicha propiedad.

El Teorema de Rao-Blackwell proporciona un procedimiento para construir nuevos estimadores insesgados con menor variabilidad a partir de un estimador inicial.

2.9.1 Enunciado

Sea $\hat{\theta}$ un estimador insesgado de un parámetro θ y sea $T(X)$ un estadístico suficiente para dicho parámetro.

Entonces:

$$\phi(T) = E(\hat{\theta} \mid T)$$

es también un estimador insesgado de θ y satisface:

$$Var[\phi(T)] \leq Var(\hat{\theta})$$

2.9.2 Interpretación

El teorema establece que la información contenida en un estadístico suficiente puede utilizarse para construir un nuevo estimador que conserve la propiedad de insesgadez y presente una variabilidad menor o igual que la del estimador original.

Por lo tanto, el estimador obtenido mediante Rao-Blackwell aprovecha de forma más eficiente la información disponible en la muestra.

2.9.3 Consecuencias

Como resultado de este teorema se obtiene que:

$$E[\phi(T)] = \theta$$

por lo que la propiedad de insesgadez se preserva.

Además,

$$Var[\phi(T)] \leq Var(\hat{\theta})$$

lo que implica una mejora en la precisión del estimador.

Dado que para estimadores insesgados se cumple:

$$ECM(\hat{\theta}) = Var(\hat{\theta})$$

también se verifica que:

$$ECM[\phi(T)] \leq ECM(\hat{\theta})$$

Por consiguiente, el procedimiento de Rao-Blackwell permite obtener estimadores que mantienen la exactitud del estimador original y, simultáneamente, reducen su error de estimación.

2.9.4 Comentario

La aplicación formal de este resultado requiere el concepto de estadístico suficiente y el Teorema de Factorización de Neyman-Fisher, los cuales serán desarrollados en capítulos posteriores.

3 Eficiencia

3.1 Definición

La eficiencia permite comparar estimadores insesgados de un mismo parámetro.

Sean $\hat{\theta}_1$ y $\hat{\theta}_2$ dos estimadores insesgados de θ . Se dice que $\hat{\theta}_1$ es más eficiente que $\hat{\theta}_2$ si:

$$Var(\hat{\theta}_1) < Var(\hat{\theta}_2)$$

3.2 Interpretación

Mientras que la insesgadez evalúa la exactitud promedio de un estimador, la eficiencia evalúa su precisión. Un estimador eficiente produce estimaciones menos dispersas alrededor del parámetro verdadero.

3.3 Justificación mediante el Error Cuadrático Medio

Si ambos estimadores son insesgados:

$$E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta$$

entonces:

$$ECM(\hat{\theta}_1) = Var(\hat{\theta}_1)$$

y

$$ECM(\hat{\theta}_2) = Var(\hat{\theta}_2)$$

Por lo tanto, entre dos estimadores insesgados, será preferible aquel que posea menor varianza.

3.4 Evidencia empírica mediante simulación

Para ilustrar la eficiencia se comparan distribuciones muestrales de la media calculadas con diferentes tamaños muestrales.

```
set.seed(123)

theta <- 50
sigma <- 10

B <- 5000

media_n10 <- replicate(
  B,
  mean(rnorm(10, theta, sigma))
)

media_n50 <- replicate(
  B,
```

```

    mean(rnorm(50, theta, sigma))
  )

datos <- data.frame(
  valor = c(media_n10, media_n50),
  grupo = factor(
    rep(c("n = 10", "n = 50"),
      each = B)
  )
)

```

Según la teoría:

$$Var(\bar{X}) = \frac{\sigma^2}{n}$$

Por lo tanto, al aumentar el tamaño muestral la varianza disminuye.

3.5 Comparación mediante densidades

```

ggplot(
  datos,
  aes(
    x = valor,
    fill = grupo,
    color = grupo
  )
) +
  geom_density(
    alpha = 0.25,
    linewidth = 1
  ) +
  geom_vline(
    xintercept = theta,
    linetype = "dashed",
    linewidth = 1
  ) +
  scale_fill_manual(
    values = c("#2978A0", "#00B295")
  ) +
  scale_color_manual(

```

```

values = c("#2978A0", "#00B295")
) +
labs(
  title = "Comparación de eficiencia",
  x = expression(hat(theta)),
  y = "Densidad",
  fill = "",
  color = ""
) +
theme_classic(base_size = 13)

```




Figura 2. Ambas distribuciones están centradas en el parámetro verdadero, pero la correspondiente a $n = 50$ presenta una menor dispersión, indicando una mayor eficiencia.

3.6 Comparación mediante diagramas de caja

```

ggplot(
  datos,
  aes(

```

```

    x = grupo,
    y = valor,
    fill = grupo
  )
) +
  geom_boxplot(
    alpha = 0.85
  ) +
  geom_hline(
    yintercept = theta,
    linetype = "dashed"
  ) +
  scale_fill_manual(
    values = c("#2978A0", "#00B295")
  ) +
  labs(
    title = "Variabilidad de las estimaciones",
    x = "",
    y = expression(hat(theta))
  ) +
  theme_classic(base_size = 13) +
  theme(
    legend.position = "none"
  )
)

```




Figura 3. La distribución asociada a un mayor tamaño muestral presenta menor dispersión, lo que refleja una mayor eficiencia.

3.7 Comparación numérica de varianzas

```
tabla_varianzas <- data.frame(
  Estimador = c(
    "Media muestral (n = 10)",
    "Media muestral (n = 50)"
  ),
  Varianza = c(
    var(media_n10),
    var(media_n50)
  )
)

knitr::kable(
  tabla_varianzas,
  digits = 4,
```



```
caption = "Comparación de varianzas empíricas"
)
```

Table 1: Comparación de varianzas empíricas

Estimador	Varianza
Media muestral (n = 10)	9.8504
Media muestral (n = 50)	1.9646

Los resultados numéricos complementan la evidencia gráfica y permiten verificar la disminución de la varianza al aumentar el tamaño muestral.

3.8 Propiedad de mínima varianza

Dentro de la clase de estimadores insesgados existe especial interés en aquellos que presentan la menor varianza posible.

$$Var(\hat{\theta}^*) \leq Var(\hat{\theta})$$

para cualquier otro estimador insesgado $\hat{\theta}$.

Esta propiedad motiva la búsqueda de estimadores óptimos en teoría de estimación.

3.9 Relación entre Insesgadez y Eficiencia: Cota de Cramér-Rao

La eficiencia de un estimador insesgado no puede evaluarse únicamente observando su varianza. Es necesario contar con una referencia teórica que permita determinar qué tan cercana se encuentra dicha varianza al mejor valor posible.

La Cota de Cramér-Rao establece que, bajo ciertas condiciones de regularidad, la varianza de cualquier estimador insesgado de un parámetro θ satisface:

$$Var(\hat{\theta}) \geq \frac{1}{I(\theta)}$$

donde $I(\theta)$ representa la información de Fisher.

Esta desigualdad proporciona una cota inferior para la varianza de los estimadores insesgados. En consecuencia, ningún estimador insesgado puede poseer una varianza menor que dicho límite.

3.10 Interpretación

La información de Fisher mide la cantidad de información que contiene una muestra respecto al parámetro desconocido. Cuanto mayor sea esta información, menor podrá ser la varianza alcanzable por un estimador insesgado.

Por tanto:

$$I(\theta) \uparrow \implies \frac{1}{I(\theta)} \downarrow$$

lo que implica una mayor precisión en la estimación.

3.11 Eficiencia Relativa

La eficiencia de un estimador insesgado puede expresarse como:

$$e(\hat{\theta}) = \frac{\frac{1}{I(\theta)}}{Var(\hat{\theta})}$$

Cuando:

$$e(\hat{\theta}) = 1$$

el estimador alcanza exactamente la Cota de Cramér-Rao y se considera eficiente en sentido óptimo.

Si:

$$0 < e(\hat{\theta}) < 1$$

el estimador sigue siendo insesgado, pero no aprovecha toda la información disponible en la muestra.

3.11.1 Comentario

La Cota de Cramér-Rao constituye el principal criterio teórico para evaluar la eficiencia de estimadores insesgados. Su demostración requiere el estudio de la información de Fisher y será desarrollada en un capítulo posterior.

4 Consistencia

4.1 Definición

Si $\widehat{\Theta}_n = G(X_1, X_2, X_3, \dots, X_n)$ es una secuencia de estimadores del parámetro Θ basado en una muestra aleatoria de tamaño n , se dice que $\widehat{\Theta}$ es consistente para Θ , si:

$$\lim_{n \rightarrow \infty} P[|\widehat{\theta}_n - \theta| < \epsilon] = 1$$

Esta propiedad garantiza que, a medida que el tamaño muestral aumenta, el estimador se aproxima más al valor del parámetro poblacional. Es decir, que si pudiéramos tomar muestras cada vez más grandes, podríamos saber el parámetro con cualquier precisión. Esta es considerada una propiedad mínima deseable en cualquier estimador, si este no lo tuviera, no sería útil en la práctica, puesto que incluso con una muestra muy amplia, no se garantizaría una aproximación adecuada al parámetro poblacional.

4.2 Teoremas

4.2.1 La Base de la Consistencia

Un estimador será consistente si al aumentar el tamaño de muestra, ocurren dos escenarios:

- Su sesgo tiende a desaparecer.
- Su varianza tiende a cero.

Teniendo así que si estas dos condiciones se cumplen, el estimador *converge* al valor real.

El error cuadrático medio (ECM) de un estimador se descompone como $ECM = Varianza + Sesgo^2$. Si ambos términos se vuelven cero, el estimador colapsa sobre el parámetro real.

- Condición del sesgo:
 $\lim_{n \rightarrow \infty} Sesgo_{\theta}[W_n] = 0$
- Condición de la Varianza:
 $\lim_{n \rightarrow \infty} Var_{\theta}[W_n] = 0$

4.2.2 Ajuste Lineal

Teniendo un estimador consistente W_n , se puede realizar un pequeño *ajuste lineal* multiplicándolo por un número a_n y sumarle otro número b_n .

Este teorema indica que, mientras esos números de ajuste tiendan a 1 y 0 respectivamente, el estimador será consistente $U_n = a_n W_n + b_n$. Esta propiedad tiene una gran utilidad, puesto que si

se tiene un estimador como la desviación estándar (S), se quiere estimar la varianza (S^2), aplicando el teorema, justifica que elevar al cuadrado al estimador, el resultado sigue siendo consistente.

Estabilización de las constantes:

$$\lim_{n \rightarrow \infty} a_n = 1$$

$$\lim_{n \rightarrow \infty} b_n = 0$$

El nuevo estimador transformado:

$$U_n = a_n W_n + b_n$$

4.2.3 Estimadores Máximo Verosímiles (MLE)

Los estimadores de máxima verosimilitud que maximizan la función de verosimilitud $L(\theta|x)$ son siempre consistentes.

Esto significa que, usando MLE para estimar θ , con una muestra suficientemente grande, se acercará el valor sin importar el modelo. Siendo además para cualquier función continua de ese parámetro.

Función de Verosimilitud:

$$L(\theta|x) = \prod_{i=1}^n f(x_i|\theta)$$

Condición de consistencia para cualquier $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} \Pr_{\theta} \left(\left| \tau(\hat{\theta}) - \tau(\theta) \right| \geq \epsilon \right) = 0$$

4.3 Demostración para la Media Muestral

Para poder demostrar que la media muestral es un estimador consistente de la media poblacional, es posible utilizar la **Desigualdad de Chebyshev** o la **Ley Débil de los Grandes Números**.

Verificando la consistencia de la media muestral $\bar{X}_n$ mediante la desigualdad de Chebyshev:

Primer Paso: Planteamiento de la Desigualdad de Chebyshev

$$P[|\bar{X}_n - \mu| < k\sigma_{\bar{X}}] \geq 1 - \frac{1}{k^2}$$

Esta es la forma bilateral de la desigualdad, la cual se deriva de la definición de varianza:

$$P(|Y - E[Y]| \geq k\sigma_Y) \leq \frac{1}{k^2} \Rightarrow P(|Y - E[Y]| < k\sigma_Y) \geq 1 - \frac{1}{k^2}.$$

Segundo Paso: Definición de ϵ y despejando k

Se toma:

$$\epsilon = k\sigma_{\bar{X}} \Rightarrow k = \frac{\epsilon}{\sigma_{\bar{X}}}.$$

Ya que $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$ (esto es válido para muestras independientes y que se encuentren idénticamente distribuidas), entonces:

$$k = \frac{\epsilon}{\sigma/\sqrt{n}} = \frac{\epsilon\sqrt{n}}{\sigma}.$$

Tercer Paso:

Sustituyendo k en $1 - \frac{1}{k^2}$:

$$1 - \frac{1}{k^2} = 1 - \frac{1}{\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right)^2} = 1 - \frac{\sigma^2}{n\varepsilon^2}.$$

Por lo tanto:

$$P[|\bar{X}_n - \mu| < \varepsilon] \geq 1 - \frac{\sigma^2}{n\varepsilon^2}.$$

Cuarto Paso: Toma del límite cuando $n \rightarrow \infty$

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\sigma^2}{n\varepsilon^2}\right) = 1.$$

Ya que $P[|\bar{X}_n - \mu| < \varepsilon]$ se encuentra acotada inferiormente por una cantidad la cual tiende a 1, siendo la máxima probabilidad 1, nos queda:

$$\lim_{n \rightarrow \infty} P[|\bar{X}_n - \mu| < \varepsilon] = 1.$$

4.4 Verificación mediante R

```
library(pacman)
p_load(ggplot2, dplyr, tidyr)

mu <- 50
sigma <- 10
tamanos <- c(5, 10, 20, 50, 100, 500, 1000, 5000)
B <- 1000
simular_medias <- function(n, B, mu, sigma) {
  replicate(B, mean(rnorm(n, mu, sigma)))
}

resultados <- lapply(tamanos, function(n) {
  medias <- simular_medias(n, B, mu, sigma)
  data.frame(tamano = factor(n, levels = tamanos), media = medias)
})

datos_consistencia <- bind_rows(resultados)

resumen_consistencia <- datos_consistencia %>%
  group_by(tamano) %>%
  summarise(
    media_estimada = mean(media),
    varianza_estimada = var(media),
    sesgo = mean(media) - mu,
    error_cuadratico = var(media) + sesgo^2,
```

```
.groups = "drop"
)
```

```
knitr::kable(resumen_consistencia, digits = 4, caption = "Comportamiento de la media muestral a
```


Table 2: Comportamiento de la media muestral al aumentar el tamaño muestral

tamano	media_estimada	varianza_estimada	sesgo	error_cuadratico
5	49.8933	21.3499	-0.1067	21.3613
10	49.9734	9.1469	-0.0266	9.1477
20	49.9267	5.0826	-0.0733	5.0880
50	50.0694	1.9176	0.0694	1.9224
100	49.9263	1.0081	-0.0737	1.0135
500	49.9890	0.2067	-0.0110	0.2069
1000	49.9858	0.0995	-0.0142	0.0997
5000	49.9964	0.0209	-0.0036	0.0209

```
ggplot(datos_consistencia, aes(x = media, fill = tamano, color = tamano)) +
  geom_density(alpha = 0.3, linewidth = 0.8) +
  geom_vline(
    xintercept = mu,
    linetype = "dashed",
    color = "red",
    linewidth = 1.2
  ) +
  labs(
    title = "Consistencia de la media muestral",
    subtitle = paste(
      "La distribución se concentra alrededor de ",
      mu,
      "a medida que n aumenta"
    ),
    x = expression(bar(X)),
    y = "Densidad",
    fill = "Tamaño muestral (n)",
    color = "Tamaño muestral (n)",
  ) +
  theme_classic(base_size = 13) +
  scale_fill_viridis_d() +
  scale_color_viridis_d() +
  facet_wrap(~ tamano, scales = "free_y", ncol = 3)
```

Consistencia de la media muestral

La distribución se concentra alrededor de $\mu = 50$ a medida que n aumenta:



En cada simulación se verifica que la media muestral es un estimador consistente de la media poblacional. A medida que el tamaño de la muestra aumenta:

- La varianza de las estimaciones va disminuyendo.
- El sesgo tiende a ser cero.
- La distribución de las estimaciones se vuelve cada vez más concentrada al rededor del valor real.

Notar que la propiedad de consistencia es una propiedad asintótica, esto significa que si el tamaño muestral tiende al infinito es cuando se alcanzaría la media muestral al valor exacto correcto. En la realidad esto significa que para una muestra suficientemente grande, el estimador puede proporcionar una aproximación precisa al parámetro poblacional.

5 Suficiencia

Sea $X_1, X_2, \dots, X_n$ una muestra extraída de una población con función de densidad $f(x; \theta)$, y sea $T = T(X_1, X_2, \dots, X_n)$ una estadística.

Según Fisher, la estadística $T = T(X_1, X_2, \dots, X_n)$ es suficiente para efectuar inferencias sobre el parámetro cuando T “resume el conjunto de información relevante suministrada por la muestra”. Ningún otro estimador definido con la misma muestra puede suministrar información adicional respecto de .

Los análisis estadísticos se realizan mediante una reducción o condensación de la información contenida en la muestra. Esta condensación o reducción lleva a cabo la estadística $T = T(X_1, X_2, \dots, X_n)$ debe producirse sin pérdida de información y en este sentido la suficiencia reclama la propiedad de que la estadística debe tener en relación a la no pérdida de información.

Para poder comprender mejor el alcance del concepto de suficiencia y sus consecuencias, comenzamos estudiando de qué manera una estadística genera una partición del espacio muestral de observación.

$$\mathcal{X} = \{(X_1, \dots, X_n) \in \mathbb{R}^n / X_i \text{ es variable aleatoria; } i = 1, 2, \dots, n\}$$

Ejemplo 1. Sea X_1, X_2, X_3 una muestra aleatoria extraída de una población de Bernoulli $B(1; p)$. Hallar las particiones inducidas por las estadísticas.

$$T_1 = t_1(X_1, X_2, X_3) = \frac{\sum_{i=1}^3 X_i}{3} \quad \text{y} \quad T_2 = t_2(X_1, X_2, X_3) = \max\{X_1, X_2, X_3\}$$

Solución: Como $X_i \sim B(1, p)$, entonces tenemos:

$$X_i = \begin{cases} 1, & \text{si ocurre éxito con probabilidad } p, \\ 0, & \text{si ocurre fracaso con probabilidad } 1 - p = q, \end{cases} \quad \forall i = 1, 2, 3$$

Luego, el espacio muestral de observaciones generado por la muestra aleatoria es:

$$\chi = \{(0; 0; 0), (0; 0; 1), (0; 1; 0), (1; 0; 0), (0; 1; 1), (1; 0; 1), (1; 1; 0), (1; 1; 1)\}$$

En la tabla siguiente se muestran los valores que alcanza cada una de las dos estadísticas propuestas.

Muestra	$T_1 = t_1(X_1, X_2, X_3)$	$T_2 = t_2(X_1, X_2, X_3)$
(0, 0, 0)	0	0
(0, 0, 1)	$\frac{1}{3}$	1
(0, 1, 0)	$\frac{1}{3}$	1
(1, 0, 0)	$\frac{1}{3}$	1
(0, 1, 1)	$\frac{2}{3}$	1
(1, 0, 1)	$\frac{2}{3}$	1
(1, 1, 0)	$\frac{2}{3}$	1
(1, 1, 1)	1	1

Tabla1. Resultados de los estadísticos.

Así, la partición por $T_1 = t_1(X_1, X_2, X_3)$ está formada por los siguientes subconjuntos:

$$\begin{aligned}\chi_1 &= \{(0; 0; 0)\}, & \chi_2 &= \{(0; 0; 1), (0; 1; 0), (1; 0; 0)\} \\ \chi_3 &= \{(0; 1; 1), (1; 0; 1), (1; 1; 0)\}, & \chi_4 &= \{(1; 1; 1)\}\end{aligned}$$

Análogamente, la partición inducida por $T_2 = t_2(X_1; X_2; X_3)$ está constituida por los siguientes dos subconjuntos.

$$\chi_1 = \{(0; 0; 0)\}, \quad \chi_2 = \{(0; 0; 1), (0; 1; 0), (1; 0; 0), (0; 1; 1), (1; 0; 1), (1; 1; 0), (1; 1; 1)\}$$

5.1 Definición

Sea $X_1, X_2, \dots, X_n$ una muestra aleatoria extraída de una población con función de densidad $f(x; \theta)$.

Se dice que una estadística $T = t(X_1, X_2, \dots, X_n)$ es suficiente para θ , si y sólo si la distribución condicional de $X = (X_1, X_2, \dots, X_n)$ dado $T = t(X_1, X_2, \dots, X_n)$ es independiente de θ , $\forall \theta$, esto es:

$$P[\underline{X} = \text{nderline{x}} / T = t] \text{ no depende de } \theta.$$

La idea es que si uno conoce el valor de la estadística suficiente $T = t(X_1, X_2, \dots, X_n)$, entonces los valores muestrales así solos no son necesarios para tomar decisiones acerca de θ ; y esto es verdadero, pues la distribución muestra dado el valor de la estadística suficiente $T = t$ no depende de θ . Uno no puede esperar para enterarse de algo acerca de θ mediante los valores muestrales si su distribución no depende de θ .

Teorema 3.- (Criterio de Factorización Fisher-Neyman)

Sea $X_1, \dots, X_n$ una muestra aleatoria extraída de una población con función de densidad $f(x; \theta)$. La estadística $T = t(X_1, \dots, X_n)$ es suficiente para θ , si y sólo si, existen funciones g_θ y h tal que la densidad conjunta de $X_1, \dots, X_n$ se puede factorizar como

$$f(x_1, \dots, x_n; \theta) = g_\theta(t(x_1, \dots, x_n))h(x_1, \dots, x_n) = g_\theta(T)h(x_1, \dots, x_n)$$

donde la función $h(x_1, \dots, x_n)$ es no negativa y no depende del parámetro θ , y la función $g_\theta(t(x_1, \dots, x_n))$ es no negativa y depende del parámetro θ y de la muestra, solamente a través de la estadística $T = t(x_1, \dots, x_n)$.

Teorema 4.- (Criterio de Factorización)

Sea $X_1, \dots, X_n$ una muestra aleatoria extraída de una población con función de densidad de probabilidad $f(x; \theta)$, donde $\underline{\theta} = (\theta_1, \dots, \theta_k) \in \Theta \subset \mathbb{R}^k$. Una estadística m-dimensional

$$T = t(X_1, \dots, X_n) = (t_1(X_1, \dots, X_n), \dots, t_m(X_1, \dots, X_n)) = (T_1; T_2; \dots; T_m)$$

es suficiente para $\underline{\theta}$, si y sólo si, la densidad conjunta de $X_1, \dots, X_n$ se factoriza como sigue

$$\begin{aligned}f(x_1, \dots, x_n; \underline{\theta}) &= g_{\underline{\theta}}(t(x_1, \dots, x_n))h(x_1, \dots, x_n) \\ &= g_{\underline{\theta}}((t_1(x_1, \dots, x_n), \dots, t_m(x_1, \dots, x_n)))h(x_1, \dots, x_n)\end{aligned}$$

donde $g_{\underline{\theta}}$ es una función no negativa y depende de $x_1, \dots, x_n$ sólo a través de T y h es una función independiente de θ .

Ejemplo 2.- Sea $X_1, \dots, X_n$ una muestra aleatoria extraída de una población $N(\mu; 1)$. Hallar una estadística suficiente para μ .

Solución: La función de densidad de probabilidad de la distribución $N(\mu; 1)$ es dado por:

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}} e^{-1/2(x-\mu)^2} = (2\pi)^{-1/2} \exp \left\{ -\frac{1}{2}(x^2 - 2\mu x + \mu^2) \right\}$$

Luego la densidad conjunta de la m.a. $X_1, \dots, X_n$ es

$$\begin{aligned} f(\underline{x}; \mu) &= \prod_{i=1}^n f(x_i; \mu) = \prod_{i=1}^n (2\pi)^{-1/2} \exp \left\{ -\frac{1}{2}x_i^2 + \mu x_i - \frac{1}{2}\mu^2 \right\} \\ &= (2\pi)^{-n/2} \exp \left\{ -\frac{1}{2} \sum x_i^2 + \mu \sum x_i - \frac{n\mu^2}{2} \right\} \\ &= (2\pi)^{-n/2} \exp \left\{ \mu \sum_{i=1}^n x_i - \frac{n\mu^2}{2} \right\} \cdot \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\} \\ &= (2\pi)^{-n/2} \exp \left\{ \mu T - \frac{n\mu^2}{2} \right\} \cdot \exp \left\{ -\frac{1}{2} \sum_{i=1}^n x_i^2 \right\} = g_{\mu}(T) h(\underline{x}) \end{aligned}$$

donde $h(\underline{x}) = \exp \left\{ -\frac{1}{2} \sum x_i^2 \right\}$; $g_{\mu}(T) = \frac{1}{(2\pi)^{n/2}} \exp \left\{ \mu T - \frac{n}{2}\mu^2 \right\}$

Por tanto, $T = t(\underline{X}) = \sum_{i=1}^n X_i$ es una estadística suficiente para μ .

5.2 Implementación en R

Para ilustrar el resultado obtenido, se genera una muestra aleatoria de una distribución Normal $N(\mu, 1)$ y se calcula la estadística suficiente

$$T = \sum_{i=1}^n X_i.$$

```
# Fijar semilla
```

```
set.seed(123)
```

```
# Parámetros
```

```
mu <- 5
```

```
n <- 20
```

```
# Generar muestra aleatoria N(mu,1)
```

```
x <- rnorm(n, mean = mu, sd = 1)
```

```
# Estadística suficiente
```

```
T <- sum(x)
```

```
# Mostrar muestra
```

```
x
```

```
## [1] 4.439524 4.769823 6.558708 5.070508 5.129288 6.715065 5.460916 3.734939
```

```
## [9] 4.313147 4.554338 6.224082 5.359814 5.400771 5.110683 4.444159 6.786913
```

```
## [17] 5.497850 3.033383 5.701356 4.527209
```

```
# Mostrar estadística suficiente
```

```
T
```

```
## [1] 102.8325
```

La estadística suficiente obtenida es:

$$T = \sum_{i=1}^n X_i.$$

De acuerdo con el Teorema de Factorización de Fisher-Neyman, toda la información contenida en la muestra respecto al parámetro μ queda resumida en esta estadística.

```
library(ggplot2)
```

```
datos <- data.frame(x = x)
```

```
ggplot(datos, aes(x = x)) +  
  geom_histogram(aes(y = after_stat(density)),  
                 bins = 8,  
                 fill = "skyblue",  
                 color = "black",  
                 alpha = 0.8) +  
  geom_density(linewidth = 1.2, color = "red") +  
  geom_vline(xintercept = mu,  
             color = "darkgreen",  
             linewidth = 1.2,  
             linetype = "dashed") +
```

```
labs(
  title = "Muestra aleatoria de una distribución N(5,1)",
  subtitle = paste("Estadística suficiente T =", round(T,2)),
  x = "Valores observados",
  y = "Densidad"
) +
theme_classic(base_size = 13)
```




Figura4. Distribución generada a partir de una población $N(5,1)$

La figura muestra la distribución de la muestra generada a partir de una población $N(5,1)$. La línea vertical punteada representa la media poblacional $\mu = 5$. Para esta muestra, la estadística suficiente para μ es $T = \sum_{i=1}^n X_i$, cuyo valor observado es T .

Ejemplo 3.- Sea $X_1, \dots, X_n$ una m.a. extraída de una población $N(\mu; \sigma^2)$ y sea $\underline{\theta} = (\mu; \sigma^2)$ el vector de parámetros. Hallar una estadística suficiente para $\underline{\theta}$.

Solución: La función conjunta de la muestra es:

$$\begin{aligned}
f(\underline{x}; \underline{\theta}) &= \prod_{i=1}^n f(x_i; \underline{\theta}) = \prod_{i=1}^n (2\pi)^{-1/2} \cdot \sigma^{-1} \cdot \exp \left\{ -\frac{1}{2\sigma^2} (x_i - \mu)^2 \right\} \\
&= (2\pi)^{-n/2} \cdot \sigma^{-n} \cdot \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \\
&= \frac{1}{(2\pi)^{n/2} \cdot \sigma^n} \cdot \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{\mu}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\mu^2}{2\sigma^2} \right\} \\
&= \frac{1}{(2\pi)^{n/2} \cdot \sigma^n} \cdot \exp \left\{ -\frac{1}{2\sigma^2} T_2 + \frac{\mu}{\sigma^2} T_1 - \frac{n\mu^2}{2\sigma^2} \right\} = g_{\underline{\theta}}(T_1; T_2) h(\underline{x})
\end{aligned}$$

donde $h(\underline{x}) = 1$; $g_{\underline{\theta}}(T_1; T_2) = \frac{1}{(2\pi)^{n/2} \cdot \sigma^n} \cdot \exp \left\{ -\frac{1}{2\sigma^2} T_2 + \frac{\mu}{\sigma^2} T_1 - \frac{n\mu^2}{2\sigma^2} \right\}$

Por tanto, $T = t(\underline{X}) = (\sum_{i=1}^n X_i; \sum_{i=1}^n X_i^2)$ es una estadística suficiente para $\underline{\theta} = (\mu; \sigma^2)$

Ejemplo3: Estadística suficiente para una población Normal

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población

$$N(\mu, \sigma^2)$$

Aplicando el Teorema de Factorización de Fisher-Neyman se obtiene que

$$T(\mathbf{X}) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$$

es una estadística suficiente para el vector de parámetros

$$\theta = (\mu, \sigma^2).$$

5.3 Verificación mediante simulación en R

```

# Fijamos semilla para reproducibilidad
set.seed(123)

# Parámetros poblacionales
mu <- 10
sigma <- 2
n <- 20

# Generación de la muestra
x <- rnorm(n, mean = mu, sd = sigma)

```

```
# Estadísticas suficientes
```

```
T1 <- sum(x)
```

```
T2 <- sum(x^2)
```

```
# Resultados
```

```
T1
```

```
## [1] 205.665
```

```
T2
```

```
## [1] 2186.806
```

La salida proporciona los valores observados de

$$T_1 = \sum_{i=1}^n X_i$$

y

$$T_2 = \sum_{i=1}^n X_i^2,$$

que constituyen una estadística suficiente para (μ, σ^2) .

```
library(ggplot2)
```

```
datos <- data.frame(
```

```
  i = 1:n,
```

```
  x = x
```

```
)
```

```
# Cálculo de estadísticos suficientes
```

```
T1 <- sum(x)
```

```
T2 <- sum(x^2)
```

```
ggplot(datos, aes(x = i, y = x)) +  
  geom_point(size = 2, color = "steelblue") +  
  geom_line(color = "gray60", alpha = 0.6) +  
  labs(  
    title = "Muestra aleatoria de N( , ^2)",
```

```

subtitle = paste0("T1 =  $\sum X_i =$ ", round(T1,2),
                  " | T2 =  $\sum X_i^2 =$ ", round(T2,2)),
x = "Índice i",
y = "Valores de la muestra"
) +
theme_classic(base_size = 13)

```




Figura5.

EL gráfico muestra la muestra aleatoria generada de una población $N(\mu, \sigma^2)$. Toda la información relevante sobre los parámetros (μ, σ^2) queda resumida en las estadísticas suficientes $T_1 = \sum X_i$ y $T_2 = \sum X_i^2$, lo que confirma el resultado obtenido mediante el teorema de factorización de Neyman-Fisher.

6 Conclusiones

Insensgidez

Esta propiedad fue verificada tanto teórica como aplicativa para la media muestral. La demostración teórica demostró que:

$$E(\bar{X}) = \mu$$

confirmando que la media muestral no presente algún sesgo en la estimación de la media poblacional.

Para el caso de la varianza, se evidenció que el estimador natural $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ es sesgado:

$$E(S_n^2) = \frac{n-1}{n} \sigma^2$$

justificando así la corrección de Bessel:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Además, la simulación realizada con 10000 repeticiones y $n = 30$ mostró un sesgo casi nulo, confirmando el resultado teórico.

Eficiencia

En la comparación de eficiencia entre estimadores con diferentes tamaños muestrales pudo demostrar claramente que la media muestra con $n = 50$ es más eficiente que con $n = 10$, presentando una varianza mucho menor:

$$Var(\bar{X}_{10}) = 9.8504 \quad \text{y} \quad Var(\bar{X}_{50}) = 1.9646$$

La eficiencia como tal es una propiedad crucial, pues permite elegir entre estimadores insesgados para un mismo nivel de exactitud, eligiendo el que ofrezca mayor precisión.

Consistencia

Se pudo ver en la simulación realizada demostrar que la media muestral es un estimador consistente de la media poblacional. Los resultados mostraron que:

Para $n = 5$, la varianza era de aproximadamente 21.35.

Para $n = 5000$, la varianza se pudo reducir hasta aproximadamente 0.02.

Es esta disminución de la varianza con el tamaño muestral que muestra la propiedad de consistencia. Un añadido el cual fue el sesgo el cual tiende a cero a medida que n aumenta relacionando así la probabilidad del estimador al parámetro poblacional.

Suficiencia

La muestra aleatoria proveniente de una población normal $N(\mu, \sigma^2)$ puede ser completamente resumida mediante la estadística bidimensional $(T_1, T_2) = (\sum X_i, \sum X_i^2)$, la cual es suficiente para el vector de parámetros (μ, σ^2) . Esto implica que no se pierde información relevante sobre los parámetros al reemplazar la muestra completa por estas estadísticas.

La existencia de una estadística suficiente para (μ, σ^2) confirma que la distribución normal pertenece a la familia exponencial, lo que permite reducir la dimensionalidad de los datos sin afectar la inferencia estadística. En particular, toda la información contenida en la muestra sobre los parámetros se concentra en T_1 y T_2 , facilitando el cálculo de estimadores eficientes.

En conclusión, es de vital importancia destacar que cada una de las propiedades no son independientes, sino que estas se complementan e incluso a veces entran en conflicto dado que un estimador puede ser *sesgado* pero eficiente, ofreciendo un menor error cuadrático medio que otro estimador

insesgado. Así también, un estimador puede ser insesgado pero inconsistente si es que su varianza no tiende a cero.

Es así que la comprensión de estas propiedades es fundamental para cualquier persona que realice cualquier tipo de análisis estadístico, puesto que proporciona la teoría necesaria para poder seleccionar y evaluar distintos estimadores de manera más rigurosa y fundamentada.

7 Bibliografía

- Mitacc Meza, M. *Tópicos de inferencia estadística* (3.^a ed.). Lima, Perú.
- Moya, R. y Saravia, G. *Probabilidad e inferencia estadística*. Perú.
- Huamani Flores, S. *Apuntes de clase del curso: Análisis estadístico*. Material de curso, Perú.
- López de Castilla Vásquez, C. (2012). *Inferencia Estadística - [Guía de curso]*. Universidad Nacional Agraria La Molina.